

基于长短期记忆神经网络的台风路径临近预报模型

GAO Song^{1,2}, ZHAO Peng^{1,2}, PAN Bin³, LI Yaru^{1,2*}, ZHOU Min³, XU Jiangling^{1,2}, ZHONG Shan^{1,2}, SHI Zhenwei³

1 国家海洋局北海海洋预报中心, 国家海洋局, 青岛 266061 2 山东省海洋生态环境与防灾减灾重点实验室, 青岛 266061 3 北京航空航天大学宇航学院图像处理中心, 北京 100191, 中国

2016 年 7 月 16 日收稿; 2017 年 8 月 16 日接受

© 中国海洋学会和德国 Springer-Verlag GmbH, Springer Nature 2018 的一部分

摘要 台风路径的准确预报对于减少人员伤亡和经济损失至关重要。气象部门积累了大量台风观测资料, 但尚未得到充分利用。利用机器学习进行预测是一种有效的方法。基于 1949-2011 年中国大陆台风观测数据, 结合大数据和数据挖掘技术, 训练长短期记忆 (LSTM) 神经网络, 建立基于机器学习的台风路径预测模型。结果表明, 所采用的算法可产生理想的 6-24 小时台风路径临近预报, 且精度有所提高。

关键词: 台风路径, 机器学习, LSTM, 大数据

引用: 高松、赵鹏、潘斌、李亚茹、周敏、徐江岭、钟山、石振伟。2018. 基于长短期记忆神经网络的台风路径预测临近预报模型。海洋学报, 37(5): 8–12, doi:10.1007/s13131-018-1219-z

1 引言台风是典型的热带天气系统, 对沿海地区人民生命财产安全和区域经济发展造成严重威胁。台风的及时预报和预警可以为防灾部门提供有效的信息支持, 有效减少人员伤亡和经济损失。因此, 准确预测台风路径是一个重要的研究课题。然而, 台风路径受台风背景场、台风系统热力学和动力学等因素的影响 (黄和金, 2013)。此外, 台风登陆后, 其路径还受到沿海地区复杂的测深和海岸线以及内陆地形等的影响 (Yu et al., 2012)。因此, 台风路径的解析是一个相当复杂、综合性的挑战。现有的预报工作前期主要依靠主观经验预报。陈和丁(1979)总结了西北太平洋台风的路径类型, 为台风路径的预测提供了经验参考。近年来, 随着监测手段和计算机技术的发展, 台风路径数值预报得到了广泛发展。目前, 台风路径预报已形成较为完整的体系, 数据丰富, 方法多样,

基于数值预测并与人机界面相结合(Qian et al., 2012)。王等人。(1996)提出了基于人工资料和观测的台风数值预报初始场方案, 并将其应用于南海台风路径的预报。钱等人。(2012)讨论了不同初始场和侧向边界条件对台风数值预报精度的影响。Li和Chen(2002)回顾了集合数值预报系统在中国的运行应用。Xu等(2014)提出了一种基于GRAPES并改进对流参数化的台风预报策略。然而, 虽然数值预报已得到广泛应用, 但精度仍低于经验预报方法(Chen等, 2015)。根据中国气象局上海台风研究所公布的数据, 目前基于主观经验方法的24 h、48 h和72 h台风路径误差预报现状分别为84.2 km、145.6 km和205.4 km, 基于区域数值模型的长度分别为 97.4 km、188.2 km 和 302.7 km (Xu 等, 2010)。进一步提高数值预报模型的精度仍然是一个挑战。目前, 包括气象卫星、海洋观测站和地面观测在内的立体台风观测系统已初步建立。

基金项目: 国家自然科学基金项目, 合同号: 61273245和41306028; 北京市自然科学基金会, 合同号: 4152031; 国家公益性海洋领域专项研究基金, 合同号: 201405022-3和2013418026-4; 国家海洋局北海分局海洋科技项目, 合同号: 2017A01; 国家海洋局海洋业务预报项目*通讯作者, E-mail: liyaru@bhj.gov.cn

帖子, 为运营部门和研究机构提供大量数据 (Hochreiter 和 Schmidhuber, 1997)。此外, 自 1949 年以来, 台风预报机构积累了大量的台风观测数据。在大数据时代, 利用这些数据提高数值预报精度是一项紧迫的任务。随着机器学习算法, 特别是循环神经网络 (RNN)、长短期记忆神经网络 (LSTM) 等的发展, 解决预测和回归问题的新方法已经出现。受 LSTM 模型在图像识别和视觉描述方面出色表现的启发(Xu et al., 2015), 本文基于深度学习算法开发了台风路径预报模型, 并进行了大量的观测深度学习算法的本质是利用大量的样本来训练一个端到端的网络, 然后通过这个训练好的网络利用测试数据进行预测。由于网络中涉及的参数较多, 需要足够的训练数据来训练模型。研究表明, 深度学习算法可以在足够的样本训练网络的情况下显着提高准确性。合理采用深度神经网络来处理大量的大数据可以提高台风路径的预测精度。RNN是目前应用最广泛的回归预测神经网络算法之一。然而, RNN 中的梯度可能会消失, 即错误无法向后传播到远的前一个神经元 (Donahue et al., 2015)。LSTM 是解决这个问题的经典方法。在 LSTM 模型中, 将含有激活函数的正常神经元替换为记忆细胞来解决梯度消失问题。同时, 由于该方案, 信息值可以在任意长度的时间内存储在网络中。兰萨托等人。(2014)提出了一种基于 LSTM 的视频解释算法。苏茨克韦尔等人。(2014)采用 LSTM 算法来预测时间序列, 并得到了合理的结果。研究表明, 深度学习算法, 特别是 LSTM, 可以应用于天气预报和海洋遥感领域。尹等人。(2015)使用深度信念网络预测了大气污染水平。尤特等人。(2016)采用基于相空间重建的传统误差反向传播神经网络来预测风暴雨。施等人。(2015)提出了一种基于卷积 LSTM 算法的降水预测模型。上述研究表明, 深度学习算法是利用大数据建立模型和进行预测的有效工具。本文提出了一种基于深度学习算法的台风路径预测模型。国家海洋局北海海洋预报中心 1949-2012 年台风路径观测资料

中国的 LSTM 神经网络被用来训练。预测了六次二十四小时的台风路径并与观测结果进行了比较。本文的贡献有三个方面: (1)全面分析了1949年和2012年的台风观测数据, 建立了台风数据集。(2)建立了基于LSTM 的深度神经网络, 利用台风大预测台风路径。数据。验证了深度学习算法在台风路径预测中的适用性。(3)预测6至24小时的台风路径, 为相关人员提供信息支持。

2 基于LSTM算法的台风路径预测模型 LSTM算法是在RNN的基础上发展起来的。LSTM 保留了循环和误差反向传播过程, 并用长短期记忆细胞代替传统 RNN 中的隐藏神经元。本节首先介绍 RNN, 为了清楚起见, 先介绍 LSTM 算法。然后应用LSTM算法建立台风路径预测模型。

2.1 RNN简介传统的前馈神经网络 (FNN) 在许多领域都有着良好的表现。然而, 它们在处理视频等时间序列时表现不佳。这主要是由于以下两个方面。首先, anFNN的输入格式是固定长度的向量。其次, FNN 区域中的样本被认为是独立的, 即它们在时间或空间上都不相关。RNN 解决了这个问题, 并在语音识别、机器翻译、图像解释等方面取得了令人满意的性能, 因为 RNN 可以逐一处理输入序列中的每个元素, 并将过滤后的信息传递到神经网络中以保留序列中的信息。系列中元素之间的相关性。与FNN相比, RNN允许输入和输出采用序列格式, 打破了数据只能逐个向前传播的限制。FNN 的输入和输出通常是固定长度的向量, 而 RNN 的输入和输出可以是时间序列, 如 (x 1, x 2, ..., x t) 和 (y 1, y 2, ..., y t), 其长度可以是有限的或无限的, 其中x和y是向量, 上标是索引号, 可以将其视为时间序列的时间。RNN 中的每个样本都是一对输入序列和输出序列。隐藏神经元的输出只能定向到 FNN 中下一层的神经元, 而在 RNN 中, 可以传递到上一层的神经元同一层及其本身, 因此, 信息的传递可以不受“时间”限制。如图所示1, 实线表示RNN中的信息流, 并且




图 1. 通过 BPTT 展开 RNN。

虚线代表没有“时间”限制的信息流。在该方案中，很难使用误差反向传播（BP）来训练RNN，因此采用反向传播时间（BPTT）方法按时间展开网络。图 1 中的左栏是 RNN 的示意图，右栏是 BPTT 展开的结构。时间步 t 的隐藏神经元可以获得当前时间步 x t 的输入信息，以及前一个时间步 h t-1 的隐藏层信息，即 h t = σ(W h x x t + W h h h t-1 + b h)。按时间展开RNN使得训练网络变得更容易，因为RNN中时间重叠的部分被展开为传统的FNN，这使得RNN方法得到广泛应用。

2.2 LSTM模型虽然RNN中引入了时间，并且当前时间步的输出可以传递到下一个时间步，但是除非下一个时间步的值与当前时间步的值相同，否则信息将会丢失，即：系列中的信息只能影响相邻元素，而不能影响更远的元素。因此，影响的时间很短，训练时信息无法在网络中保存较长时间，误差反向传播时可能会出现梯度消失或爆炸。因此，引入长短期记忆细胞来存储任意时间长度的信息，以显著减轻梯度消失或爆炸，这就是称为长短期记忆（LSTM）的非时间循环神经网络。

使用特殊的细胞结构来替代 LSTM 中原来的隐藏神经元。 LSTM 的示意图如图 2 所示，其中 σ 表示 sigmoid 函数，[] 表示乘法，下标 c 表示它是单一结构，所有实线箭头表示连接权值为 1。s c 为存储单元，是一种用于存储信息的线性元素，保证信息能够长期存储，以保持序列中元素之间的相关性。g c 是输入节点，表示时间步t的输入与之前网络状态信息的综合交互。它的值可以通过输入门ic的控制传递到存储单元。如果W是权重，b是阈值，那么。i c 为输入门，接收时间步 t 的输入和之前时间步的网络状态信息，并经过 sigmoid 函数的控制将节点 g c 的输入值传递到存储单元 s c 中。f c 是忘记门，它决定是否存储 s c 的值或




图 2. LSTM 的存储单元。

not: 权重为1则原样存储，为0则清零。O c 为输出门，接收第t时刻的输入和上一个时刻的网络状态信息。它控制sigmoid函数后sc的输入和上一个时刻的网络状态信息。它控制sigmoid函数后sc的输出。v c 为输出值。用x和h向量表示每一层的值，则

$$\begin{aligned} f_c^t &= \tanh(W_{fc}x^t + W_{fh}h^{t-1} + b_{fc}) \\ i_c^t &= \sigma(W_{ic}x^t + W_{ih}h^{t-1} + b_{ic}) \\ g_c^t &= \tanh(W_{gc}x^t + W_{gh}h^{t-1} + b_{gc}) \\ o_c^t &= \sigma(W_{oc}x^t + W_{oh}h^{t-1} + b_{oc}) \end{aligned}$$

其中 \odot 是点积。

2.3 基于LSTM的台风路径预测模型

考虑台风位置的二维坐标表示，对于持续时间连续（Delta t）的台风，其路径可以用序列表示

$$x_1^1, x_2^1, x_1^2, x_2^2, \dots, x_1^t, x_2^t, \dots, x_1^{t-1}, x_2^{t-1}$$

二维向量的坐标，的下标表示其维数，的上标表示其在序列中的索引，每两个相邻元素的时间差为 Delta t。考虑到在进行m·Delta t之后的台风位置预测时，需要前n个时间步的台风位置来显示台风路径并随后获得更准确的预测，因此LSTM的输入序列应为

$$x_1^{n-1}, x_2^{n-1}, \dots, x_1^{t-n+1}, x_2^{t-n+1}, x_1^{t-n+2}, x_2^{t-n+2}, \dots$$

x_1^t, x_2^t 对应的输出序列为

。一个输入序列和相应的输出序列构成一个样本。这样设计了一个用于台风路径预测的LSTM神经网络，该网络具有三层，即输入层、隐藏层和输出层。输入层有2n个神经元，即输入序列中每个元素的维度为2n。隐藏层由 20 个长短期记忆单元组成。输出层有2个神经元，即输出序列中每个元素的维度为2。训练网络时，所有网络参数都初始化为0到1之间的随机数，然后使用训练样本进行优化。对于每个训练样本，LSTM 神经网络都会一一读取系列中的每个元素。经过隐藏层和输出层之后导出输出向量，然后将其与标签进行比较，并通过 BPTT 算法将误差向后传播。测试过程与训练过程相同。

3 实验本节设计了两个实验。第一个用于验证台风轨迹预测LSTM网络的可行性。在第二个实验中，使用不同样本量的训练数据集来训练LSTM网络，以讨论大数据的有效性。本节所有实验数据均来自CMA-STI热带气旋最佳路径数据集，该数据集记录了1949年西北太平洋热带气旋发生的路径

2011年，台风路径采用经纬度坐标记录，平均精度为每6小时0.1°。测试结果通过平均距离误差来衡量。

3.1 可行性实验为了证明LSTM神经网络预测台风路径的可行性，本实验预测了 6 h、12 h、18 h、24 h、48 h和72 h的台风位置，并训练生成6个数据集对设置测试集比例为8:1。测试结果如图3所示。结果表明，随着预测时间的延长，预测误差增大。预测结果与主观经验方法和区域数值模型的比较见表 1。LSTM网络在6、12中获得了相对准确的结果，以及18个预测。LSTM网络的预测误差与主观经验方法和区域数值模型在24小时预测中的预测误差相当，而在48小时和72小时预测中其预测误差则大幅上升并远高于后两者。因此，只有利用LSTM网络进行24小时内的预测才有意义，这也为台风路径的预测提供了一种新的方法。

3.2 不同样本的数据集实验为了检验更大的训练数据集是否可以提高预测精度，分别使用相同的数据集进行了 6 h、12 h、18 h 和 24 h 的预测，但训练数据集中与测试数据集的样本数比例分别为2:1、3:1、4:1、5:1、6:1、7:1和8:1。实验结果如图4和表2所示。可以看出，训练数据集越大，预测误差越小，即LSTM神经网络的预测精度会随着台风路径观测量的增加而增加。

4 结论本文提出了一种基于LSTM神经网络的台风路径预测方法。热带气旋CMA-STI最优轨迹数据集用于训练和测试。结果表明，24小时预测误差与传统主观经验的误差相当。

Table 1. Prediction errors (km) of different methods

Prediction time/h	LSTM	Subjective empirical methods	Regional numerical modeling
6	45.954 0	—	—
12	63.367 0	—	—
18	101.624 3	—	—
24	105.676 8	84.2	97.4
48	332.540 7	145.6	188.2
72	974.498 5	205.4	302.7

表 2. 训练数据集中不同数量样本的实验结果

Ratio of sample numbers in the training data set to the test data set	6 h errors/km	12 h errors/km	18 h errors/km	24 h errors/km
2	124.538 2	133.687 2	153.748 2	165.683 2
3	103.423 8	93.895 5	142.489 5	162.895 3
4	71.380 6	82.986 8	138.851 0	157.741 7
5	72.032 1	75.312 8	136.997 9	142.976 1
6	71.918 1	70.068 3	134.244 2	136.910 6
7	47.212 4	67.421 5	113.758 2	115.425 5
8	45.954 0	63.367 0	101.624 3	105.676 8




图 3. LSTM 神经网络随时间的预测误差。



图 4. 训练数据集中不同数量样本的实验结果。

方法和区域数值模拟。因此，为台风路径的预测提供了一种新的、可行的方法。这也表明使用更大的训练数据集可以减少LSTM神经网络的台风路径预测误差。因此，随着台风观测数据量的不断增加，LSTM神经网络的预测精度将会提高。本文仅使用台风轨迹观测数据作为预测的输入。更多信息可以包含在未来的研究中，例如中心压力、拓扑

绘图等，以提高模型的结构和准确性。

References

陈国民, 曹青, 白丽娜. 2015. 2014年西北太平洋热带气旋预报验证. 气象月刊, 41(12): 1554–1561. Donahue J, Anne Hendricks L, Guadarrama S, et al. 2015. 用于视觉识别和描述的长期循环卷积网络. 见: IEEE 计算机视觉和模式识别会议论文集. 马萨诸塞州波士顿: IEEE, 2625–2634, doi: 10.1109/CVPR.2015.7298878. Hochreiter S, Schmidhuber J. 1997. 长短期记忆. 神经计算, 9 (8) : 1735–1780. 黄晓燕, 金龙. 2013. 基于主成分分析的台风路径人工智能预测模型. 中国大气科学学报, 37(5): 1154–1164. 李泽春, 陈德辉. 2002. 国家气象中心业务集合预报系统的开发与应用. 应用气象科学学报, 13(1): 1–15. 钱传海, 段日红, 马苏红, 等. 2012. 我国台风业务预报及其关键技术的现状与未来发展. 气象科学技术进展, 2(5): 36–43. Ranzato M A, Szlam A, Bruna J, et al. 2014. 视频 (语言) 建模: 自然视频生成模型的基线. Eprint Arxiv 石行健, 陈 Z, 王华, 等. 2015. 卷积 LSTM 网络: 降水即时预报的机器学习方法 -

ing. 见: 第 28 届神经信息处理系统国际会议论文集. 剑桥: 麻省理工学院出版社, 802–810. Sutskever I, Vinyals O, Le Q V. 2014. 使用神经网络进行序列到序列学习. 见: 第 27 届神经信息处理系统国际会议论文集. 加拿大蒙特利尔: 麻省理工学院出版社, 3104–3112. 王康令, 何安国, 薛继山. 1996. 南海地区台风踪迹数值预报的初步试验. 热带气象学报, 12 (2) : 113–121. 徐道生, 陈子同, 戴光峰, 等. 2014. 改进的积云参数化方案对 GRAPES 模型台风预报的影响. 热带气象学报, 30(2): 210–218. Xu K, Ba J, Kiros R, et al. 2015. 展示、参与和讲述: 具有视觉注意力的神经图像捕获生成. 计算机科学, 2048–2057. 徐应龙, 张岭, 高栓柱. 2010. 中国台风业务预报进展与探讨. 气象月刊, 36(7): 43–49. 尹文军, 张大伟, 严静海, 等. 2015. 基于深度学习的大数据空气污染预测. 中国环境管理学报, 7(6): 46–52. 尤成, 于福江, 袁野. 2016. 基于相空间重构的神经网络风暴潮预测方法. 海洋预报, 33(1): 59–64. 于金华, 唐吉祥, 戴玉涵, 等. 2012. 中国台风路径运行预报误差及原因分析. 气象月刊, 38(6): 695–700.